Caso de uso: predecir la respuesta a la quimioterapia

Resonancia de mama con contraste y redes convolucionales

Aprendizaje Automático · Dr. Jacinto Velasco Rebolledo

UAX Universidad Alfonso X el Sabio

UAX Universidad Alfonso X el Sabio

El problema en una frase

A partir de una resonancia tomada **antes** de empezar la quimioterapia, predecir si esa paciente alcanzará **pCR**: que tras el tratamiento no quede tumor invasivo.

1.273	12.703	38.109	70,6%
pacientes	cortes de resonancia	imágenes PNG	son pCR=0

No estás detectando un tumor que ya se ve: estás anticipando cómo va a responder a un tratamiento que aún no ha empezado.

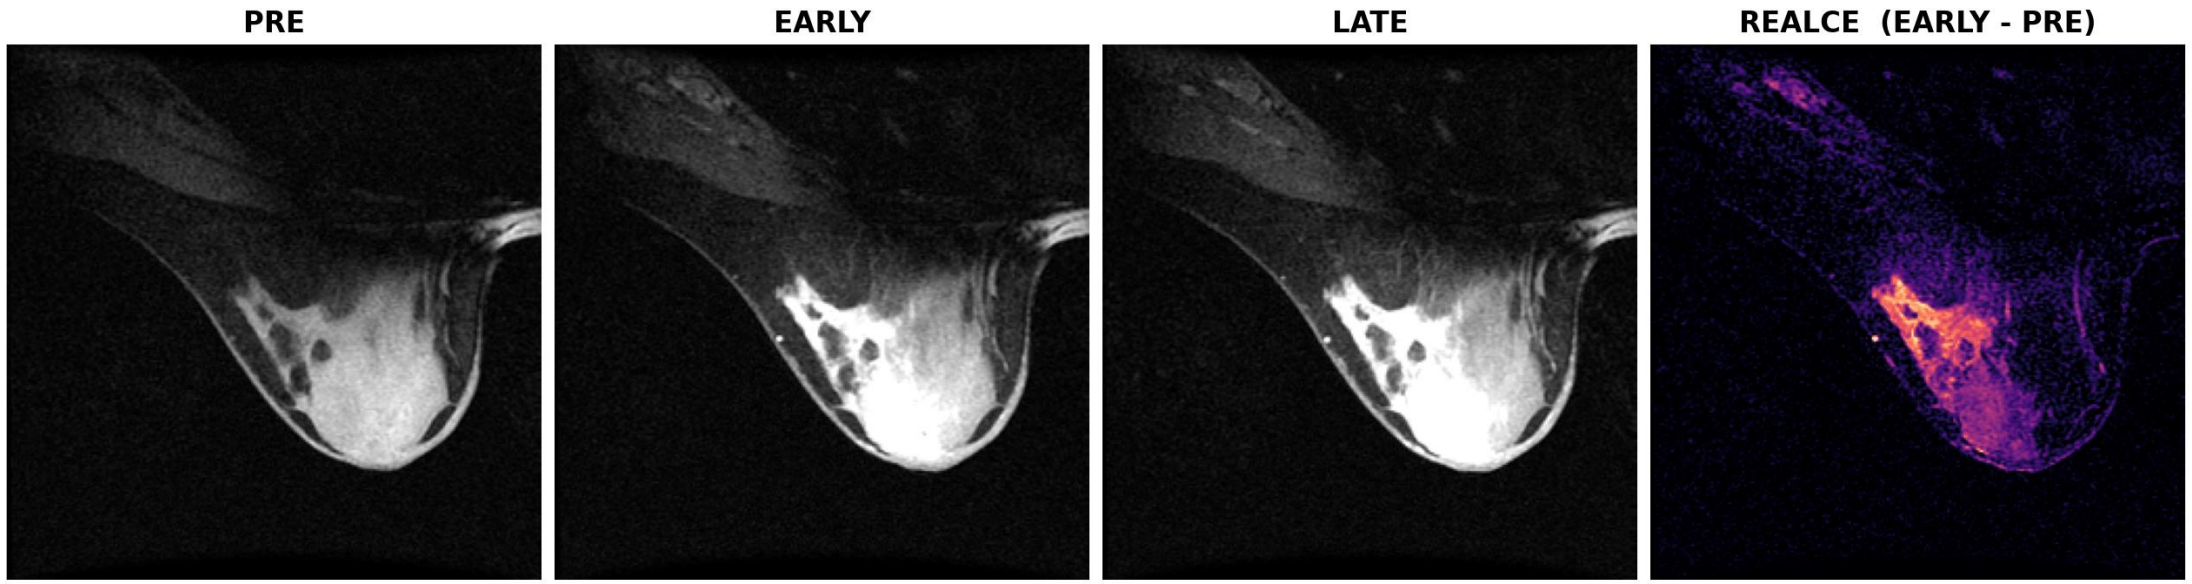
Predecir siempre pCR=0 ya acierta el 70,6%. Si tu accuracy ronda esa cifra, el modelo no ha aprendido nada.

© Dr. Jacinto Velasco Rebolledo

UAX Universidad Alfonso X el Sabio

Un corte, tres instantes

PRE, EARLY y LATE son momentos de la adquisición, no colores



El contraste entra y realza el tejido tumoral: la señal del problema está en la diferencia entre fases, no en una imagen suelta.

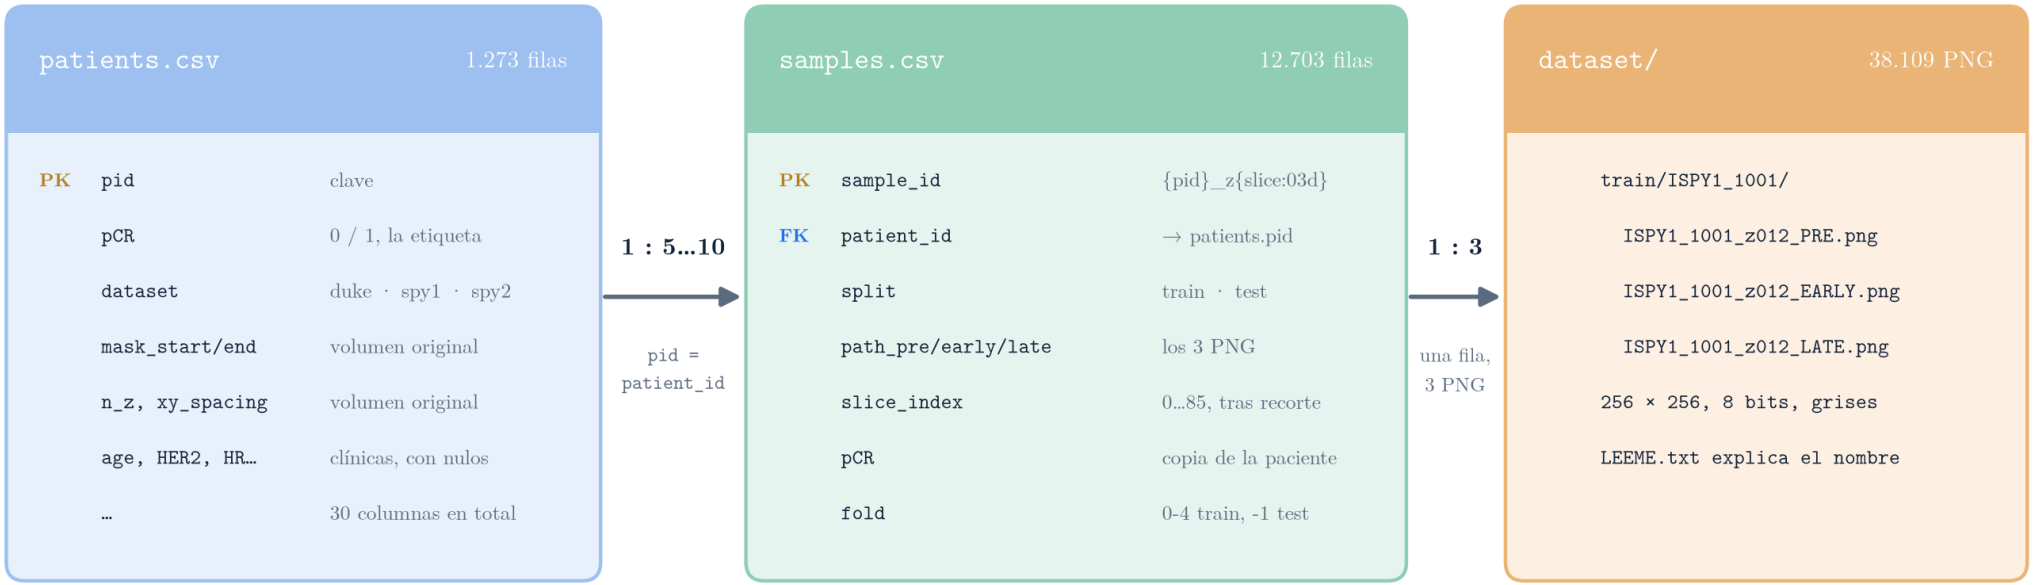
Las tres van apiladas como canales de un tensor (3, 256, 256). Cualquier giro o recorte se aplica al tensor entero.

© Dr. Jacinto Velasco Rebolledo

UAX Universidad Alfonso X el Sabio

Esquema de los datos · qué se une con qué

La clave es patient_id. Al margen: statistics.json con los totales y excluded_patients.csv con 2 pacientes descartadas.



Imprevistos que rompen el cruce

- No todas tienen 10 cortes: 7 pacientes traen entre 5 y 9
- pCR está en las dos tablas: es de la paciente, nunca del corte
- El pid tiene 4 formatos (ISPY1_1001, ISPY2-782334, ACRIN-6698-103939, Breast_MRI_002): no lo trocees
- mask_start y mask_end no acotan slice_index salvo en Duke
- Las clínicas traen nulos (menopause 172, HER2 5, age 3); pCR no
- fold = -1 no es un pliegue: marca el test
- Las rutas son relativas a breastdcedl/ y usan /, también en Windows

© Dr. Jacinto Velasco Rebolledo

UAX Universidad Alfonso X el Sabio

Caso BreastDCEDL · el camino completo

38.109 PNG · 12.703 cortes · 1.273 pacientes · predecir pCR por paciente, no por corte

1 Descargar

`descargar_datos.py`

1.273 carpetas, una por paciente.
Test incluido, con etiquetas.

2 Mirar las imágenes

`ver_muestras.py muestra`

PRE, EARLY y LATE son instantes,
no colores. El realce es la señal.

3 Construir la tabla

`uc.particion(s, fold_val=k)`

Por paciente y estratificada.
Ver el segundo diagrama.

4 Dataset y loader

`uc.BreastDCEDataset(entrena)`

x = (3, 256, 256) en [0,1].
Giros y recortes, al tensor entero.

5 CNN desde cero

`in_channels=3 → 1 logit`

Prohibido preentrenar o transferir.
3 o 4 bloques para empezar.

6 Entrenar dos veces

`pos_weight = 2,40`

7.729 cortes pCR=0 y 3.216 pCR=1.
Pérdida normal frente a ponderada.

7 Evaluar por paciente

`evaluar_por_paciente(probs, val)`

shuffle=False. Agrega los ~10 cortes:
mean, max, median o voto.

8 Test y entrega

`uc.conjunto_test(samples)`

Una sola vez, el modelo ya cerrado.
Informe, app con URL, 5 diapositivas.

Invalida el trabajo

- Cortes de una paciente en train y en validación
- Pesos preentrenados o arquitectura de catálogo
- Tocar el modelo después de haber mirado test

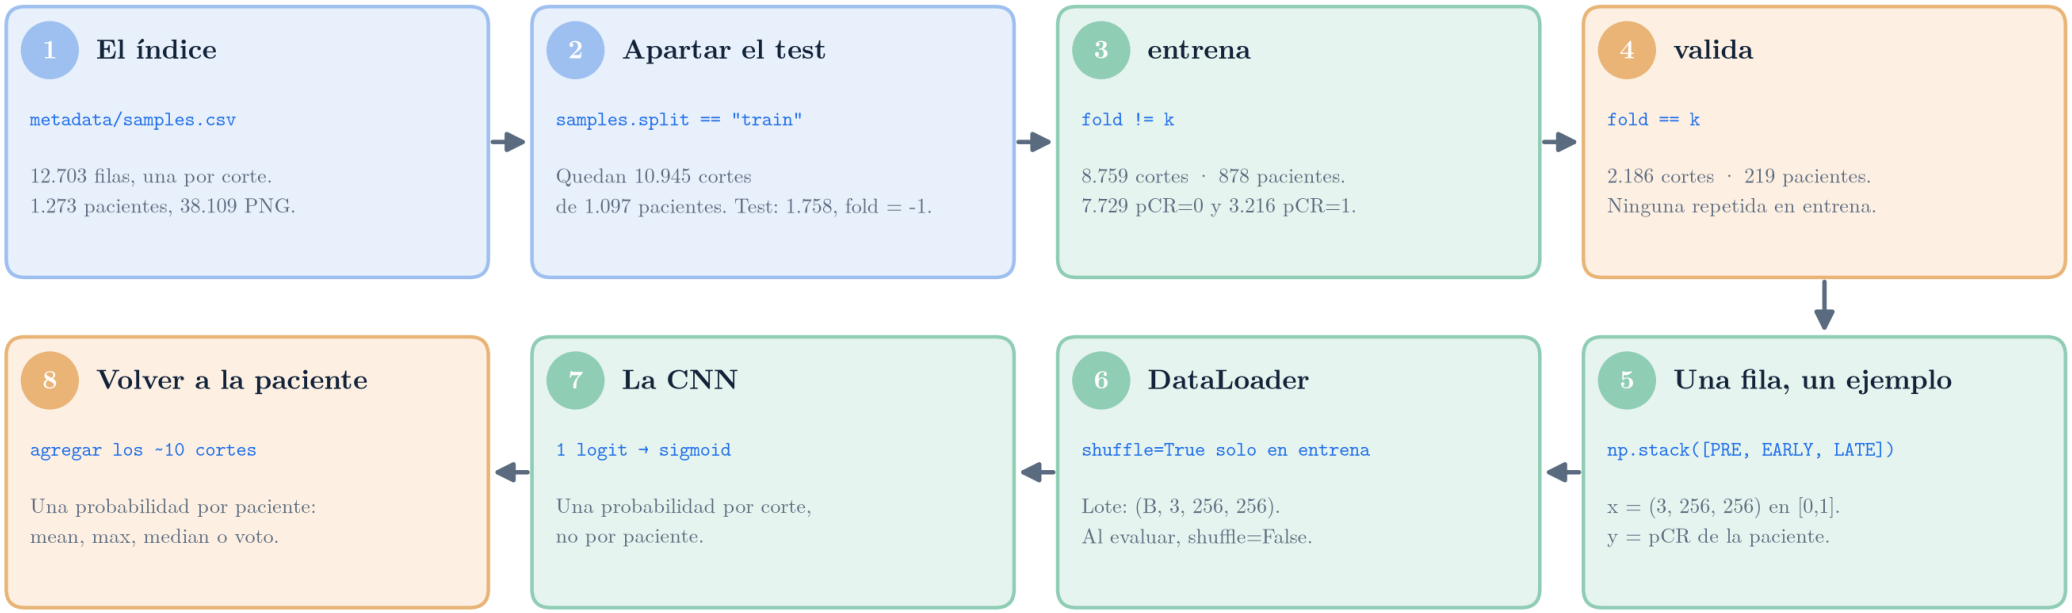
El modelo puntúa cortes, pero la nota sale de las métricas por paciente.

© Dr. Jacinto Velasco Rebolledo

UAX Universidad Alfonso X el Sabio

Cómo se construye la tabla de entrenamiento

De samples.csv al lote que entra en la CNN. Nunca se reparten filas al azar: se reparten pacientes.




```
entrena, valida = uc.particion(samples, fold_val=k)
```

k recorre 0…4 para la validación cruzada

Anula la tabla

- train_test_split sobre las filas: la misma paciente cae a los dos lados
- Barajar al evaluar: las probabilidades dejan de casar con las filas
- Elegir umbral o método de agregación mirando el test

© Dr. Jacinto Velasco Rebolledo

UAX Universidad Alfonso X el Sabio

La regla que más suspensos provoca

La unidad estadística es la paciente, no el corte

Si dos cortes de la misma paciente caen en entrenamiento y en validación

el modelo reconoce anatomía ya vista y tus métricas suben sin significar nada.

La partición ya viene hecha

La columna fold reparte por paciente y estratifica por pCR:

```
entrena, valida = uc.particion(samples, fold_val=k)
```

Cinco pliegues sobre las 1.097 pacientes de entrenamiento (10.945 cortes), sin repetir ninguna:

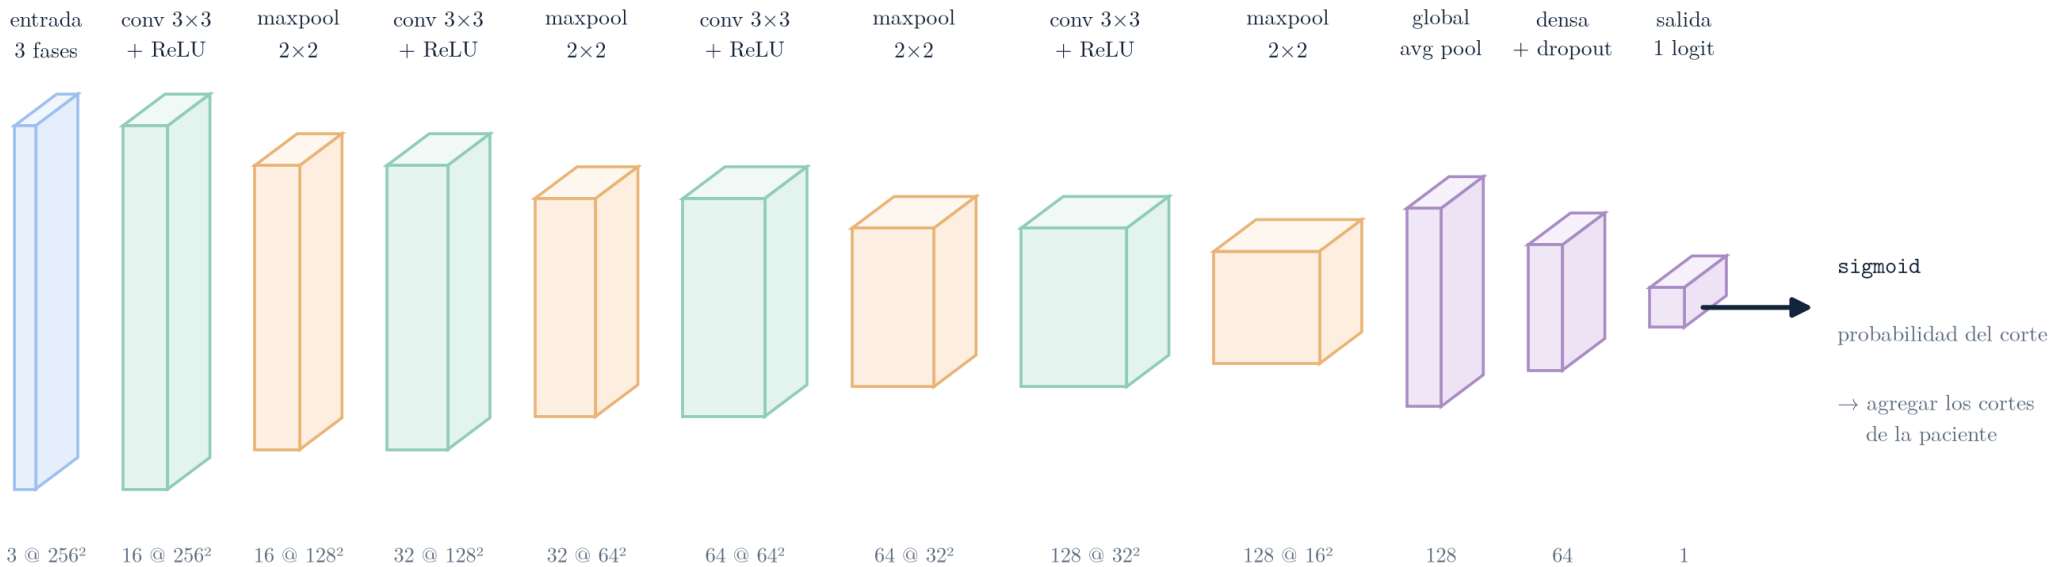
fold 0	fold 1	fold 2	fold 3	fold 4
2.186 cortes	2.190 cortes	2.192 cortes	2.192 cortes	2.185 cortes
219 pacientes	219 pacientes	220 pacientes	220 pacientes	219 pacientes

© Dr. Jacinto Velasco Rebolledo

UAX Universidad Alfonso X el Sabio

Arquitectura de referencia · el embudo de la CNN

Cada bloque estrecha el mapa y ensancha los canales. Es un punto de partida, no la solución: la tuya la justificas tú.



Lo que hay detrás

- in_channels=3 por las tres fases DCE, no por color · ≈ 105.761 parámetros
- Cada pooling divide el lado entre 2: 256 → 128 → 64 → 32 → 16
- GAP en vez de flatten: 128 valores en vez de 32.768, y menos sobreajuste
- Una sola salida: el logit entra en BCEWithLogitsLoss; la sigmoide, solo al evaluar

© Dr. Jacinto Velasco Rebolledo

Todo el detalle está en GUIA.md, dentro de la carpeta del caso.

jvelareb@uax.es

UAX Universidad Alfonso X el Sabio